Trabajo Práctico Final: Telco Churn

Ciencia de Datos (I5521) – Ingeniería Industrial – UTN FRBA – 2026
Alumna: Camila Aramayo

1 Introducción y objetivos

La empresa Telco NN quiere saber qué clientes van a dejar la compañía (*churn*) para poder ofrecerles una acción de retención antes de que se vayan. Para esto nos dieron un dataset con 7.043 clientes y 21 variables.

Los objetivos del trabajo fueron:

- Hacer un análisis exploratorio (EDA) para revisar la calidad de los datos y ver qué características de los clientes se relacionan con el churn.
- Armar un *pipeline* de Machine Learning para predecir la variable `Churn`, comparando varios modelos vistos en clase.
- Aplicar un método de reducción de la dimensionalidad (PCA) y volver a predecir.
- Traducir los resultados en una decisión para la empresa: a qué clientes conviene ofrecerles la retención.

2 Descripción del dataset

Cada fila es un cliente. Las variables son: un identificador (`customerID`); 4 variables demográficas (`gender`, `SeniorCitizen`, `Partner`, `Dependents`); la antigüedad en meses (`tenure`, de 0 a 72); 9 servicios contratados (teléfono, líneas múltiples, tipo de internet y 6 servicios adicionales de internet); 3 variables de contrato y facturación (`Contract`, `PaperlessBilling`, `PaymentMethod`); el cargo mensual y el total (`MonthlyCharges`, `TotalCharges`); y el target `Churn` (Yes/No). En total quedan 3 variables numéricas y 16 categóricas, sin contar el ID.

Al revisar el archivo encontramos algunos problemas:

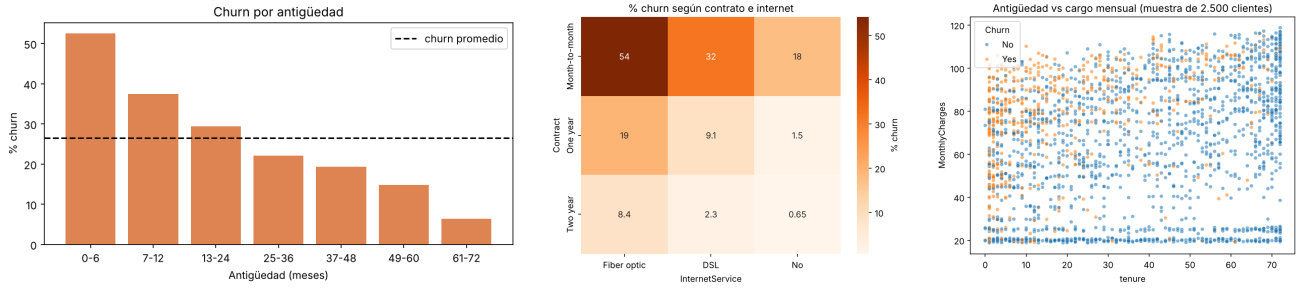
- Una columna extra (`Unnamed: 0`), que es el índice que quedó al exportar el CSV.
- `TotalCharges` venía como texto porque tiene 11 espacios en blanco. Son clientes con `tenure` = 0, o sea recién dados de alta, así que su gasto total es 0.
- Hay muchos valores faltantes: 10 variables tienen 916 vacíos (13%) y otras 4 (`Contract`, `PaperlessBilling`, `PaymentMethod` y `MonthlyCharges`) tienen 1.197 (17%). Están repartidos entre muchos clientes distintos: solo el 12% de los clientes tiene todos los datos completos. Si borráramos las filas con algún faltante perderíamos el 88% de los datos, así que decidimos imputar.
- No hay clientes duplicados ni outliers (según la regla del rango intercuartil).

3 Análisis exploratorio de datos

El target está **desbalanceado**: el 26,5% de los clientes se fue y el 73,5% se quedó. Por eso un modelo que diga siempre "no se va" tendría 73,5% de accuracy sin aprender nada. Esto nos llevó a usar el AUC como métrica principal y a estratificar las particiones.

Los hallazgos principales fueron:

- **Antigüedad:** es la variable numérica que más diferencia a los grupos. Los que se van tienen una antigüedad mediana de 10 meses, contra 38 de los que se quedan. De los clientes con menos de 6 meses se va el 53%, y de los que tienen más de 5 años, el 6% (Fig. 1a). La relación no es lineal: el churn baja rápido al principio y después se estabiliza.
- **Cargo mensual:** los que se van pagan más por mes (mediana \$79 contra \$65).
- **Contrato:** con contrato mes a mes se va el 43%, con contrato anual el 11% y con bianual el 3%. Es la variable categórica donde más cambia el churn entre categorías.
- **Servicios y pago:** los que no tienen seguridad online o soporte técnico se van un 42%, contra 15% de los que sí los tienen. Con fibra óptica se va el 42% (DSL 19%, sin internet 7%), y con cheque electrónico el 46% (los otros medios de pago, entre 16% y 19%).
- **Variables sin relación:** `gender`, `PhoneService` y `MultipleLines` casi no cambian el churn. Hombres y mujeres se van igual (26,7% y 26,5%).
- **Interacción:** con mes a mes y fibra óptica se va el 54%, pero con contrato bianual los de fibra casi no se van (8%). El churn se concentra en clientes nuevos que pagan caro (Fig. 1b).
- **Correlación:** `TotalCharges` está muy correlacionada con `tenure` (Pearson 0,82), porque el gasto total es más o menos la antigüedad por el cargo mensual. Hay información repetida.
- **Cantidad de servicios:** entre los clientes con internet, los que no tienen ningún servicio adicional se van un 50%, y los que tienen los 6, un 4%.



(a) (b)

Figura 1: (a) Porcentaje de churn por tramo de antigüedad. (b) Porcentaje de churn según contrato y tipo de internet, y antigüedad vs. cargo mensual coloreado por churn.

4 Materiales y métodos

Preprocesamiento. Primero corregimos los tipos de datos y completamos faltantes con reglas lógicas que usan solo los datos de cada cliente:

- Si algún servicio adicional dice "No internet service", el cliente no tiene internet (y al revés).
- Si `MultipleLines` dice "No phone service", el cliente no tiene teléfono.
- `TotalCharges` $\approx$ `tenure` $\times$ `MonthlyCharges`. Antes de usar esta regla la probamos con los clientes completos: el error medio fue de menos de 1 mes en `tenure` y de menos de \$2 en el cargo mensual.

Con esto recuperamos 3.216 valores, entre el 83% y el 87% de los faltantes de `tenure`, `MonthlyCharges` y `PhoneService`, y los clientes completos pasaron de 847 a 1.459. El resto de los faltantes se imputa dentro de un `Pipeline` de scikit-learn: con la mediana las numéricas y con la moda las categóricas. Después se estandarizan las numéricas y se aplica *one-hot encoding* a las categóricas, lo que deja 46 features. Hacerlo dentro del pipeline evita el *data leakage*, porque todo se ajusta solo con los datos de entrenamiento.

Modelos. Comparamos un baseline (`DummyClassifier`, que le asigna a todos la misma probabilidad), regresión logística con regularización L2, KNN, árbol de decisión, Random Forest, Gradient Boosting y una red neuronal (`MLPClassifier`).

Protocolo. Separamos 80% para entrenar y 20% para test (5.634 y 1.409 clientes), estratificando para mantener el 26,5% de churn. Los hiperparámetros de cada modelo se buscaron con `GridSearchCV` y validación cruzada estratificada de 5 folds sobre train, usando el AUC-ROC como métrica. El mejor modelo se eligió por el AUC de validación cruzada, y el test se usó una sola vez al final.

Umbral por costos. Usamos la matriz de costos vista en clase: ofrecer la retención cuesta 120 y perder un cliente cuesta 1.000. Conviene ofrecer la retención si $1000 \cdot p > 120$, es decir, si la probabilidad de que el cliente se vaya es mayor a $p^* = 0{,}12$.

PCA. Aplicamos PCA sobre las 46 features estandarizadas, ajustado solo con train y dentro del pipeline. Luego volvimos a entrenar la regresión logística y el Gradient Boosting sobre las componentes, probando distintas cantidades de componentes.

5 Experimentos y resultados

Tabla 1: Resultados de cada modelo: AUC en validación cruzada (media $\pm$ desvío entre folds) y métricas en test con umbral 0,5.

Modelo	AUC CV	AUC test	Sensibilidad	Especificidad	Accuracy
Gradient Boosting	**0,842 $\pm$ 0,012**	**0,847**	0,51	0,92	0,81
Random Forest	0,840 $\pm$ 0,010	0,841	0,47	0,92	0,80
Regresión logística	0,839 $\pm$ 0,013	0,835	0,54	0,89	0,80
Red neuronal (MLP)	0,838 $\pm$ 0,012	0,836	0,51	0,90	0,80
KNN ($k = 101$)	0,830 $\pm$ 0,012	0,825	0,58	0,86	0,79
Árbol de decisión	0,823 $\pm$ 0,014	0,833	0,47	0,91	0,79
Baseline	0,500	0,500	0,00	1,00	0,74

Todos los modelos superan claramente al baseline (Tabla 1). **Gradient Boosting** tuvo el mejor AUC en validación cruzada (0,842) y en test (0,847). Sin embargo, la diferencia con Random Forest, la regresión logística y la red es menor que el desvío entre folds (~0,012), así que en la práctica están empatados. El árbol de decisión solo fue el peor, y Random Forest y Gradient Boosting lo superan: los ensambles reducen el error de un árbol

individual. Los resultados en test son parecidos a los de validación cruzada (Fig. 2).

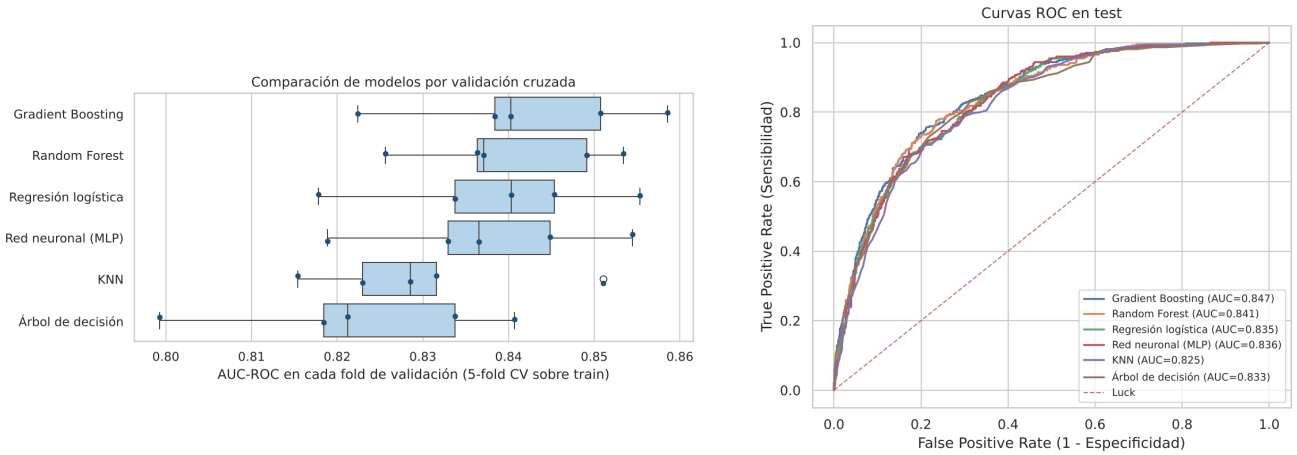


Figura 2: Izquierda: AUC de cada modelo en los 5 folds de validación cruzada. Derecha: curvas ROC en test.

Umbral de decisión. Con el umbral de 0,5, el Gradient Boosting detecta solo el 51% de los clientes que se van. En el test, no hacer nada cuesta 374.000, ofrecerle la retención a todos cuesta 169.080, y usar el modelo con umbral 0,5 cuesta 217.360: sale más caro que ofrecer a todos. Con el umbral de 0,12 la sensibilidad sube al 94% (352 de 374) y el costo baja a **124.720**, un 26% menos que ofrecer a todos, contactando a 856 clientes en lugar de 1.409. A cambio, la accuracy baja de 0,81 a 0,63. El mínimo de la curva de costos cae justo en 0,12 (Fig. 3).

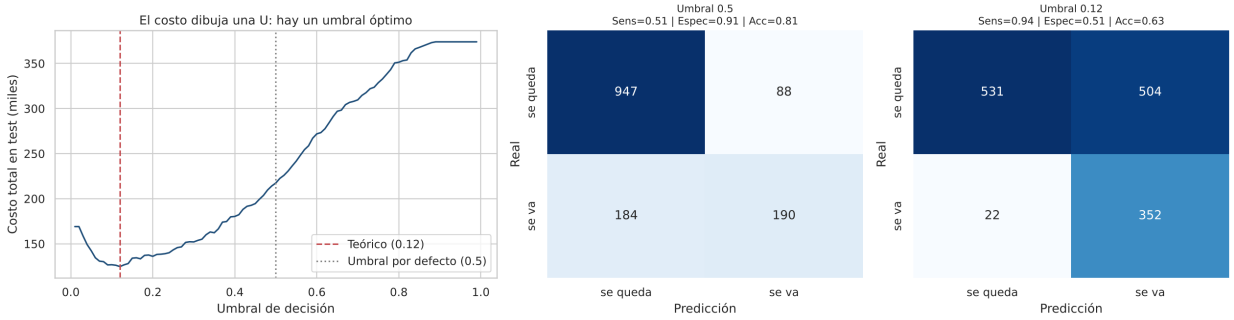


Figura 3: Costo total en test según el umbral (Gradient Boosting) y matrices de confusión con umbral 0,5 y 0,12.

Reducción de la dimensionalidad. Con 13 componentes se explica el 80% de la varianza, con 16 el 90% y con 21 el 99%. A partir de la componente 24 la varianza explicada es 0: con 23 componentes ya está toda la información, porque hay columnas repetidas (las 7 dummies de "No internet service" son iguales). PC1 separa a los clientes sin internet de los que tienen internet, y PC2 representa la antigüedad y el tipo de contrato (Fig. 4).

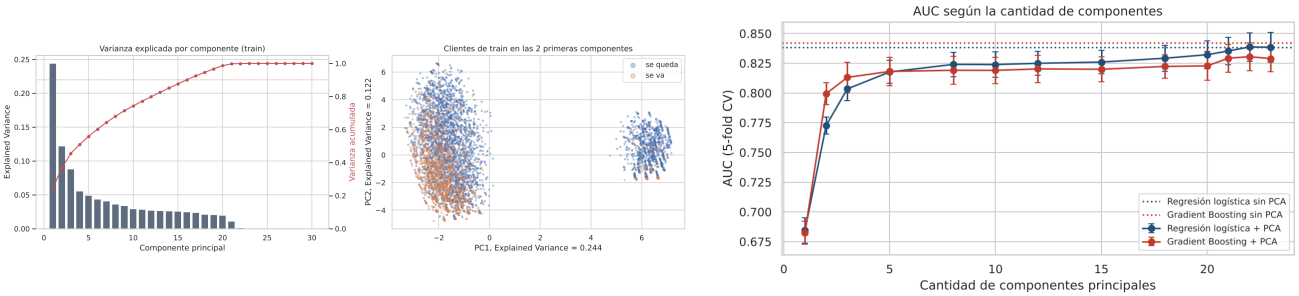


Figura 4: Izquierda: varianza explicada por componente y clientes de train en PC1–PC2. Derecha: AUC en validación cruzada según la cantidad de componentes.

Mirando el gráfico elegimos dos opciones para evaluar en test: 23 componentes (toda la información) y 5 componentes (donde el AUC ya llega a ~0,82).

Tabla 2: AUC en test con y sin PCA.

Modelo	Sin PCA (46 features)	PCA 23 componentes	PCA 5 componentes (56% var.)
Regresión logística	0,835	0,835	0,811
Gradient Boosting	0,847	0,829	0,820

La regresión logística con 23 componentes da exactamente lo mismo que con las 46 features: el PCA solo sacó la información repetida. Con 5 componentes el AUC baja entre 0,02 y 0,03, pero con 9 veces menos variables. El Gradient Boosting empeora incluso con 23 componentes (Tabla 2).

6 Discusión y conclusiones

- Se puede predecir el churn con buena capacidad: el mejor modelo tiene un AUC de 0,847 en test, muy por encima del azar (0,5). La regresión logística queda prácticamente empatada con los ensambles, lo que indica que la mayor parte del problema se puede resolver con un modelo lineal. Como es más simple y fácil de explicar, es una buena alternativa para la empresa.
- **El umbral importa tanto como el modelo.** Con el umbral de 0,12, que sale de los costos, el modelo es peor en accuracy pero mejor para el negocio. El valor del modelo está en ordenar a los clientes por riesgo para gastar el presupuesto de retención donde más rinde.
- El perfil de riesgo que surge del EDA es: cliente nuevo, contrato mes a mes, fibra óptica, cargo mensual alto, pago con cheque electrónico y sin seguridad ni soporte técnico. Esto sugiere incentivar los contratos largos y el débito automático, ofrecer seguridad y soporte en los primeros meses y revisar el precio y la calidad de la fibra.
- **PCA** mostró que la dimensión real de los datos es 23 y no 46, pero no mejoró la predicción. Con 46 features para 5.634 clientes no tenemos el problema de la maldición de la dimensionalidad. Además, como el PCA busca las direcciones de mayor varianza y no las que mejor separan las clases, las componentes con poca varianza también ayudaban a predecir. En los árboles empeora porque el PCA mezcla las variables y se pierden los cortes simples por variable (por ejemplo, "¿contrato mes a mes?"). También se pierde interpretabilidad.
- **Limitaciones:** imputamos con la moda entre el 13% y el 17% de las variables demográficas y de contrato, los datos son de un solo momento y los costos de la retención son supuestos. Para mejorar el modelo haría falta información del comportamiento del cliente, como reclamos o uso del servicio.

Referencias

[1] G. James, D. Witten, T. Hastie, R. Tibshirani y J. Taylor. *An Introduction to Statistical Learning with Applications in Python*. Springer, 2023.

[2] T. Hastie, R. Tibshirani y J. Friedman. *The Elements of Statistical Learning*, 2.ª ed. Springer, 2009.

[3] A. Géron. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*, 2.ª ed. O'Reilly, 2019.

[4] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[5] Cátedra de Ciencia de Datos (ClusterAI), UTN FRBA. Material de clases y notebooks del curso, 2026.